

```
from IPython.display import set_matplotlib_formats
set_matplotlib_formats('pdf', 'svg')
```

**EC4301 MACROECONOMETRÍA****Estudiantes: David Gerardo Mora Salazar, Manfred Ramírez Alfaro****Tarea 1:**

Profesor: Randall Romero Aguilar, PhD

Fecha límite de entrega: viernes 21 de mayo de 2021, 6pm

Pregunta 2:

(a) (4 puntos) ¿Es este proceso estacionario?

$$(1 - 0.2L - 0.24L^2)y_t = 5.6 + \epsilon_t$$

Las raíces del polinomio de rezagos $1 - 0.2z - 0.24z^2$ son iguales a $z_1 = \frac{5}{3}$ y $z_2 = \frac{-5}{2}$. El valor absoluto de estas raíces son mayores a 1, por tanto, esta ecuación es estacionaria.

(b) (6 puntos) Utilice las ecuaciones de Yule-Walker para calcular sus primeras 3 autocorrelaciones ρ_1 , ρ_2 , y ρ_3 .

$$\rho_1 = \frac{0.2}{1-0.24} = 0.2631$$

$$\rho_2 = 0.2 * 0.2631 + 0.24 = 0.2926$$

$$\rho_3 = 0.2 * 0.2926 + 0.24 * 0.2631 = 0.1217$$

(c) (5 puntos) Obtenga una simulación de T=240 períodos de este proceso, partiendo de valores iniciales $y_0 = 11$, $y_1 = 11.6$. Para ello, escriba un programa en R, Python o Stata, y fije la "semilla" de números aleatorios en 2020. Grafique sus resultados.

```
/*En Stata*/
cls
/*=====
arma-simulations.do: Simulaciones de modelos ARMA

Basado en Becketti 2013 Introduction to Time Series Using Stata
file gdp-2.do

Universidad de Costa Rica
Escuela de Economía
Curso: EC4301 Macroeconometría
Estudiantes: David Gerardo Mora Salazar, Manfred Ramírez Alfaro
=====*/

* Ajustes varios de STATA
graph drop _all
set autotabgraphs on

clear
set more off
capture log close
log using arma_simulations, replace


* Ajustes de parámetros para simulaciones
clear
set obs 240
generate int t = _n
tsset t
set seed 2020

*=====> Proceso de ruido blanco


generate epsilon = rnormal()
ac epsilon, name(acplot, replace) lags(20)
pac epsilon, name(pacplot, replace) lags(20)
graph combine acplot pacplot, name(WN)

*=====> Proceso AR(2), phi=0.2, 0.24

generate ar2 = epsilon
replace ar2 = 0.2*11.6+0.24*11 + epsilon in 3/1
ac ar2, name(acplot, replace) lags(20)
pac ar2, name(pacplot, replace) lags(20)
graph combine acplot pacplot, name(ar2)
*Gráfico
tsline ar2, recast.connected
```



(d) (5 puntos) Grafique el autocorrelograma y el autocorrelograma parcial de esta serie simulada.



Pregunta 5:

Obtenga los datos disponibles del IMAE tendencia ciclo de Costa Rica, usando el servicio web del BCCR.

```
#Pregunta 5
from bccr import SW
from bccr import GUI
import seaborn as sns
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import requests
import io
import xlrd
from scipy import stats
from statsmodels.tsa.arima_model import ARIMA
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.tsa.seasonal import seasonal_decompose
from scipy.stats import norm
from bccr import GUI
GUI()
```

```
SW(),
```

```
IMAE = SW(IMAE=35553)
```

```
SW.quien(35553)
```

```
* Running on http://127.0.0.1:8050/ (Press CTRL+C to quit)
127.0.0.1 - - [21/May/2021 01:48:04] "GET /_alive_5b07b1b5-fc06-483a-a12a-ba5d0e421a06 HTTP/1.1" 200 10
Dash app running on:
http://127.0.0.1:8050/
Variable 35553 >>>
  Nombre      : IMAE Tendencia Ciclo.
  Descripcion : IMAE Tendencia Ciclo.
  Unidad      : Nivel.
  Periodicidad: Mensual.

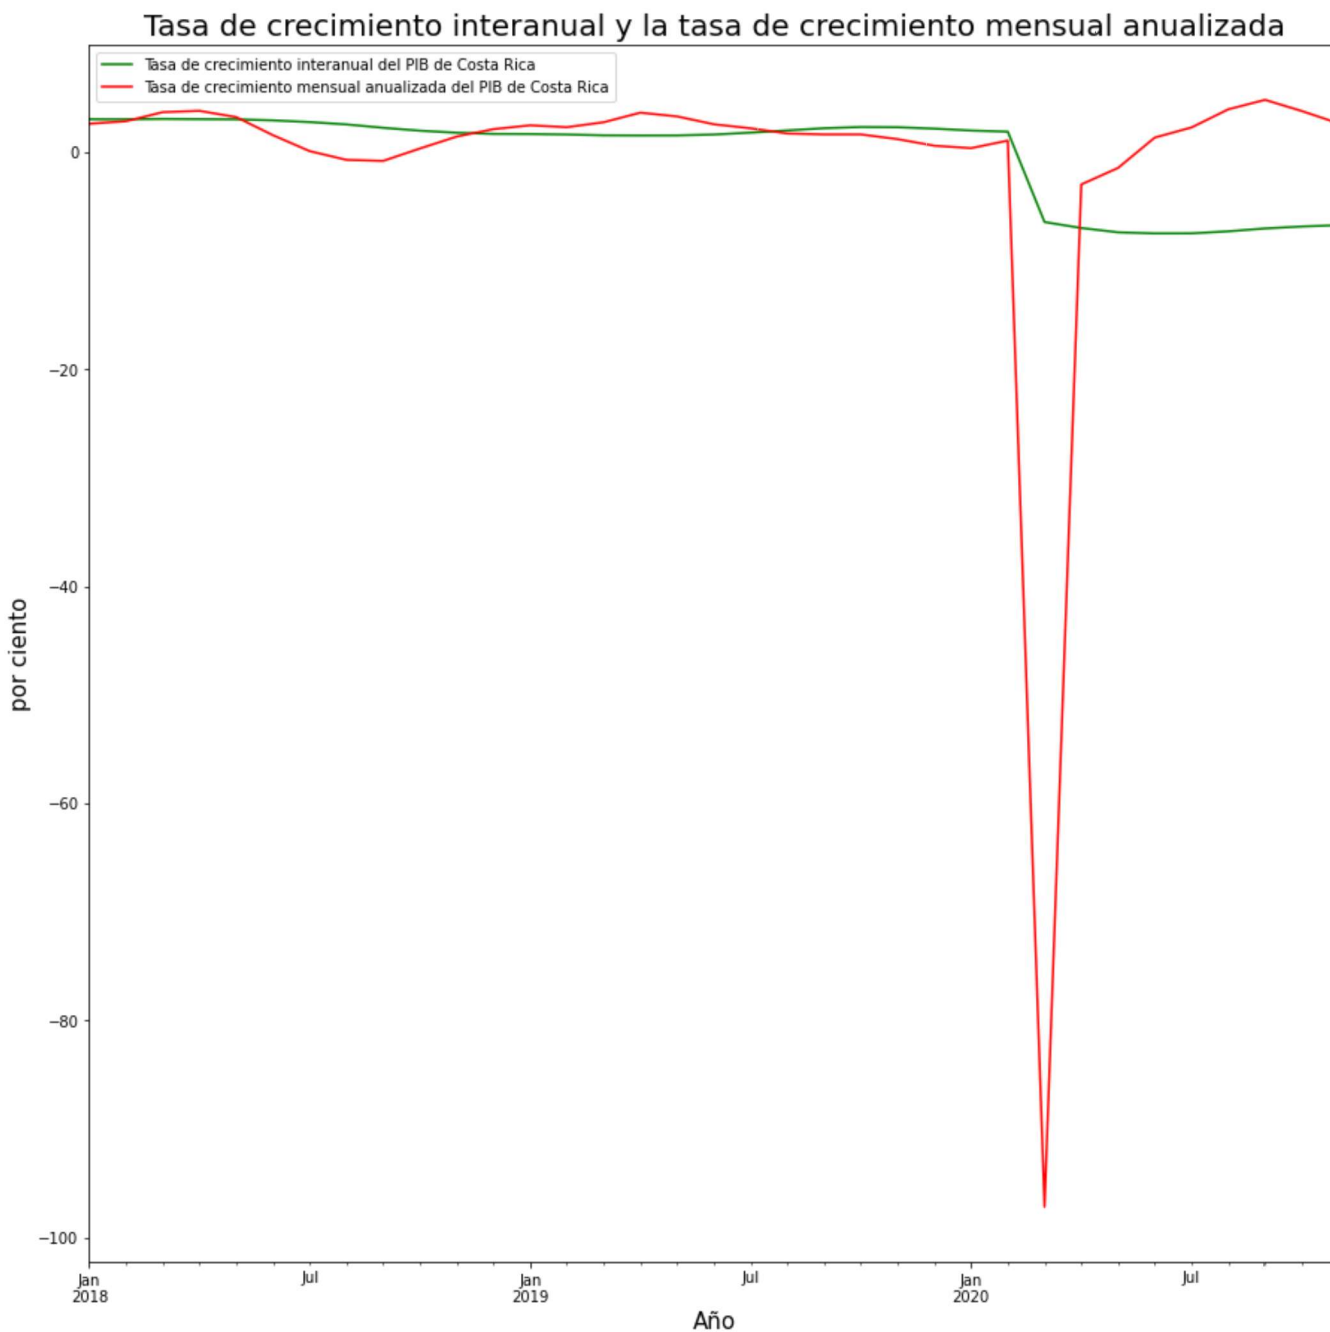
|--- Sector Real
|----- IMAE Tendencia Ciclo [35553]'
```

(a) (4 puntos) A partir del logaritmo de la serie, calcule la tasa de crecimiento interanual y la tasa de crecimiento mensual anualizada (simplemente multiplicando por 12 la tasa mensual), y grafique ambas tasas (solo datos desde enero de 2018) en un mismo gráfico.

```
#a
tasa_int = (100*np.log(IMAE).diff(12)).rename(columns= {'IMAE':'Interanual'})
tasa_anual= (100*np.log(IMAE).diff()*12).rename(columns= {'IMAE':'Anualizada'})

tasa_int['Anualizada'] = tasa_anual
fecha = tasa_int['2018':'2020']

def figura1(dato1, dato2, leyenda1, leyenda2, titulo, y):
    variable_de_apoyo1 = dato1
    variable_de_apoyo2 = dato2
    IPCrespaldo = fecha.copy()
    IPCrespaldo['variable_de_apoyo1'] =variable_de_apoyo1
    IPCrespaldo['variable_de_apoyo2'] =variable_de_apoyo2
    IPCrespaldo['variable_de_apoyo1'].plot(color="green", label=leyenda1)
    IPCrespaldo['variable_de_apoyo2'].plot( color = "red", label=leyenda2)
    plt.rcParams["figure.figsize"] = (15,15)
    plt.legend(fontsize=10)
    plt.title(titulo, fontsize=20)
    plt.xlabel(xlabel= "Año",fontsize=15)
    plt.ylabel(ylabel= y,fontsize=15)
    plt.show()
    return
figura1(fecha['Interanual'], fecha['Anualizada'], "Tasa de crecimiento interanual del PIB de
```



(b) (4 puntos) Explique por qué difieren tanto las dos series durante 2020.

Difieren significativamente debido a que la primera tasa toma todos los valores mensuales hasta el año anterior para calcular la tasa de crecimiento, es decir, es la suma de las tasas de crecimiento de cada mes, por tanto suaviza la variación que puede haber de un mes a otro. Mientras que la

segunda tasa calcula la tasa de crecimiento mensual y lo multiplica por 12, por tanto, le da más peso a la variación de un mes a otro. Por eso, cualquier efecto esporádico, afecta en mayor porcentaje a la tasa que pese más ese efecto.

(c) (8 puntos) Asumiendo que la tasa de crecimiento mensual anualizada es estacionaria, estime un modelo ARMA(p, q) utilizando datos únicamente hasta diciembre de 2019 (es decir, no incluya los datos de 2020 en su estimación del ARMA). Considere únicamente especificaciones en las que $p \leq 4$ y $q \leq 4$. Justifique su elección de valores p y q.

```
#c
#Creación del criterio de selección
#Akaike
anualizada_2019 = tasa_anual[:'2019'].dropna()
pmax = 4
qmax = 4
P = np.arange(pmax+1)
Q = np.arange(qmax+1)
aic = [[ARIMA(anualizada_2019, order=[p,0,q]).fit().aic for q in Q ] for p in P ]
AIC = pd.DataFrame(aic, index=[f'p={p}' for p in P], columns=[f'q={q}' for q in Q])
AIC
# Recomienda p=4 y q=4
#Bayesiano
bic = [[ARIMA(anualizada_2019, order=[p,0,q]).fit().bic for q in Q ] for p in P ]
BIC = pd.DataFrame(bic, index=[f'p={p}' for p in P], columns=[f'q={q}' for q in Q])
BIC
#Recomienda p=1 y q=3
#En este caso, los criterios no coinciden, por lo que se recomienda el de Bayes.
#Estimación con p=1 y q=3
res = ARIMA(anualizada_2019, order=[1,0,3]).fit()
res.summary()
```

Akaike:

	q=0	q=1	q=2	q=3	q=4
p=0	1654.577950	1211.314423	842.045060	768.872397	733.756077
p=1	1070.610889	793.423866	719.563209	684.630414	685.964118
p=2	985.864517	781.445731	795.801974	689.811434	688.572720
p=3	924.350269	759.248412	784.906917	783.640850	687.833084
p=4	901.253588	751.271970	761.014510	769.502032	683.459397

Bayesiano:

	q=0	q=1	q=2	q=3	q=4
p=0	1662.276600	1222.862398	857.442360	788.119021	756.852026
p=1	1082.158863	808.821165	738.809833	707.726363	712.909392
p=2	1001.261816	800.692355	818.897922	716.756708	719.367318
p=3	943.596892	782.344361	811.852190	814.435448	722.477007
p=4	924.349536	778.217243	791.809109	804.145955	721.952645

SARIMAX Results						
=====						
Dep. Variable:	Anualizada	No. Observations:	347			
Model:	ARIMA(1, 0, 3)	Log Likelihood	-336.315			
Date:	Thu, 20 May 2021	AIC	684.630			
Time:	19:59:09	BIC	707.726			
Sample:	02-28-1991	HQIC	693.826			
	- 12-31-2019					
Covariance Type:	opg					
=====						
	coef	std err	z	P> z	[0.025	0.975]

const	3.6340	0.552	6.578	0.000	2.551	4.717
ar.L1	0.8836	0.033	26.466	0.000	0.818	0.949
ma.L1	1.4545	0.065	22.295	0.000	1.327	1.582
ma.L2	-0.0658	0.121	-0.541	0.588	-0.304	0.172
ma.L3	-0.5210	0.063	-8.224	0.000	-0.645	-0.397
sigma2	0.3885	0.022	17.454	0.000	0.345	0.432
=====						
Ljung-Box (L1) (Q):		0.13	Jarque-Bera (JB):	102.35		
Prob(Q):		0.72	Prob(JB):	0.00		
Heteroskedasticity (H):		0.25	Skew:	0.22		
Prob(H) (two-sided):		0.00	Kurtosis:	5.62		
=====						

Estimación:

La elección de los valores p y q provienen de un proceso de selección que sugiere el uso de un modelo parsimoniosos, es decir, usar tan pocos parámetros como sea necesario, pues esta metodología tiene sus beneficios a la hora de hacer pronósticos. Entonces se realiza análisis de diagnóstico para confirmar que el modelo es consistente con los datos observados. Los criterios más usuales para analizar la concistencia son el de Akaike (Akaike) y el de Bayes (BIC) y por tanto, se escoge la combinación p y q que minimiza el criterio de información, sin embargo, al tener una disyuntiva entre la cantidad de rezagos con el ajuste del modelo y la precisión, se tuvo que elegir una combinación de p y q que minimiza ese criterio de información. De esta manera, calculando ambos criterios, ambos difieren en su selección apropiada, pero debido a las propiedades del criterio de información Bayesiano, pues el Bayesiano es más riguroso en la penalización de los parámetros de manera que no se pierda precisión, por eso se escogió la combinación p=1 y q=3 que escogió el Bayesiano.

(d) (8 puntos) Utilice su modelo estimado para pronosticar la serie en 2020. Grafique sus pronósticos con intervalos de confianza del 90%.

```
#d
horizon = 12
ff= res.forecast(steps=horizon, alpha=0.1)#alpha de significancia
std = res.forecast(steps=horizon, alpha=0.1)#alpha de significancia
conf = res.forecast(steps=horizon, alpha=0.1)#alpha de significancia
alpha = np.arange(1,6)/10
zvalues = norm(0, 1).isf(np.array(alpha)/2)
# Datos pronosticados
```



```

fcast = pd.DataFrame({'Anualizada pronosticada':ff,'std':std}, index=pd.period_range(anualiza

# Concatenar los datos observados con los pronosticados
fcast2 = pd.concat([anualizada_2019,fcast], sort=False)
fcast2['$\mu$'] = anualizada_2019.values.mean()


# Graficar la serie y el pronóstico
fig, ax =plt.subplots(figsize=[12,4])
fcast2.loc['2007-01':'2020-12']["Anualizada",'Anualizada pronosticada','$\mu$'].plot(ax=ax)
plt.title("Crecimiento pronosticado del IMAE tendencia-ciclo", fontsize=20)
plt.xlabel(xlabel= "Año",fontsize=15)
plt.ylabel(ylabel= "Crecimiento pronosticado del IMAE",fontsize=15)

def intervalo(z):
    """
    Para calcular los límites superior e inferior del intervalo de confianza,
    dado el valor crítico de la distribución normal
    """
    return fcast2['Anualizada pronosticada']+z*fcast2['std'], fcast2['Anualizada pronosticad

# fechas para graficar los intervalos
d = fcast2.index.values


# Graficar los intervalos de confianza
for z in zvalues:
    ax.fill_between(d, *intervalo(z), facecolor='blue', alpha=0.12, interpolate=True) #alpha

```



(e) (6 puntos) Compare su pronóstico con los datos publicados por el BCCR para 2020. Calcule los errores de pronóstico. Comente: ¿es este un buen modelo de pronóstico? Justifique su respuesta.

Pronóstico de la tasa de crecimiento para 2020 y la verdadera tasa de crecimiento mensual anualizada



#Errores del pronóstico

```
datos_pronosticados = fcast2.loc['2020-01':'2020-11'][['Anualizada pronosticada']]
```

```
datos_observados = fecha.loc['2020-01':'2020-11']["Anualizada"]
```

```
datos_pronosticados = pd.DataFrame(datos_pronosticados)
```

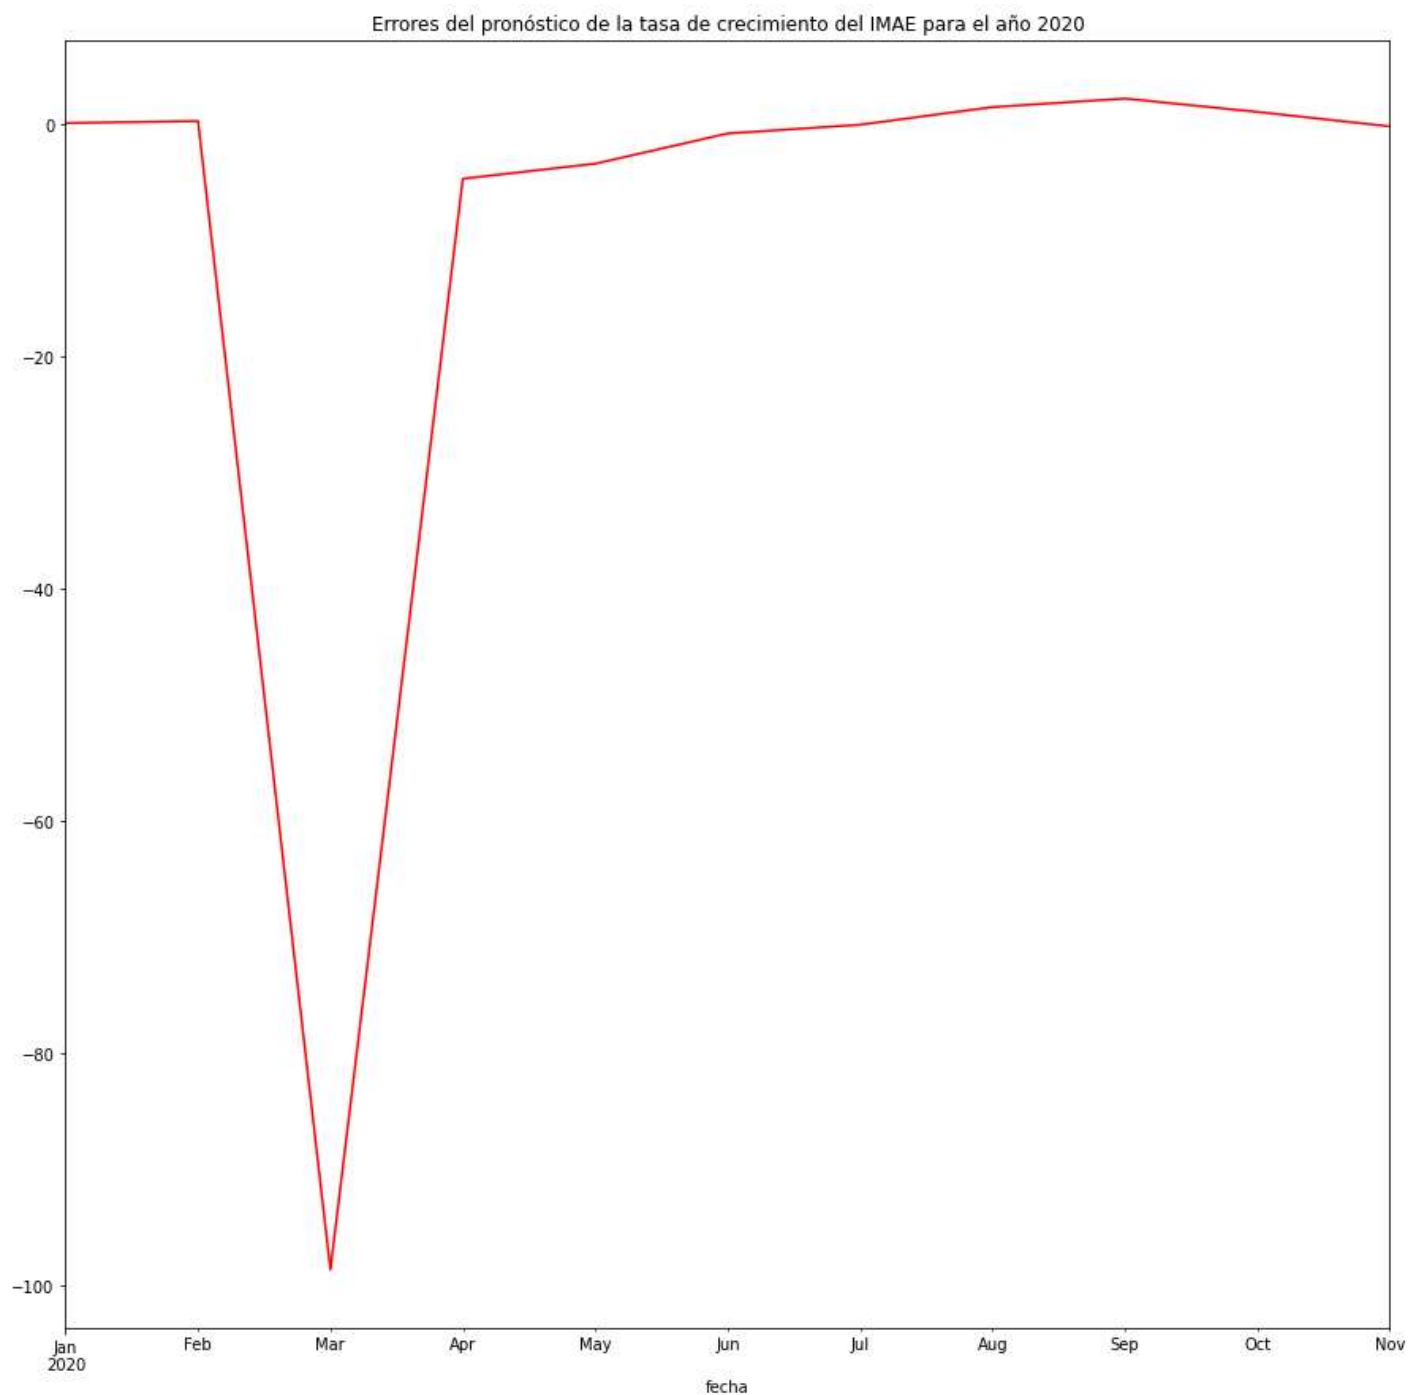
```
datos_observados = pd.DataFrame(datos_observados)
```

```
error = datos_observados["Anualizada"] - datos_pronosticados["Anualizada pronosticada"]
```

```
error.plot(kind='line', x='Fecha', y='Errores', color='red')
```

```
plt.title("Errores del pronóstico de la tasa de crecimiento del IMAE para el año 2020")
```

```
plt.show()
```



```
fecha
2020-01    0.118237
2020-02    0.298829
2020-03   -98.605597
2020-04    -4.670095
2020-05    -3.374498
2020-06    -0.774818
2020-07    -0.018739
2020-08     1.496663
2020-09     2.231995
2020-10     1.083606
2020-11    -0.161289
Freq: M, dtype: float64
```

Este es estadísticamente un buen modelo de pronóstico, pues este procedimiento es aquel que minimiza el error cuadrático medio, por eso, lo definimos como el mejor pronóstico de este tipo. Claramente, no siempre va a pronosticar con exactitud, pero es el mejor. Otra característica de este pronóstico con el menor error cuadrático medio es la esperanza de todos los valores pronosticados condicional en los datos existentes.

✓ 4 s se ejecutó 20:12

